



**UNIVERSIDADE ESTADUAL DA PARAÍBA
CAMPUS I
CENTRO DE CIÊNCIAS E TECNOLOGIA
DEPARTAMENTO DE ESTATÍSTICA
BACHARELADO EM ESTATÍSTICA**

DISCENTE: Eduarda Da Silva Brito

DOCENTE: Pedro Monteiro de Almeida Júnior

ANÁLISE DE SÉRIES TEMPORAIS

Atividade 1

**CAMPINA GRANDE - PB
2026**

Introdução

As séries temporais são conjuntos de dados observações ou métricas registrados sequencialmente em intervalos de tempo regulares (diário, mensal, anual). Elas mostram a evolução de uma variável, permitindo analisar tendências, ciclos e padrões, sendo fundamentais para previsões futuras em áreas como finanças, meteorologia e monitoramento de sistemas.

Entre os principais componentes de uma série temporal destacam-se a tendência, a sazonalidade e sem tendência. A tendência representa o comportamento de crescimento ou redução da série ao longo do tempo. A sazonalidade corresponde aos padrões que se repetem em intervalos regulares, como meses ou estações do ano. Já os sem tendência representa oscilações não previsíveis presentes nos dados.

A análise de séries temporais possui grande relevância prática, pois permite compreender o comportamento histórico das variáveis e auxiliar na realização de previsões futuras. Além disso, técnicas gráficas e métodos estatísticos possibilitam decompor as séries em diferentes componentes, facilitando a interpretação dos dados.

Nesta atividade foram analisados diferentes conjuntos de dados temporais, considerando frequências diárias, mensais e trimestrais. O objetivo foi verificar como a transformação da escala temporal influencia a visualização e interpretação das séries.

Objetivos Específicos

Os objetivos específicos que serão abordados são:

- Construir gráficos de séries temporais;
- Identificar padrões de tendência nas séries;
- Verificar a presença de sazonalidade;
- fazer a transformação dos dados originais para anual ou trimestral;
- Interpretar os componentes das séries temporais.

Metodologia

Para o desenvolvimento deste trabalho foram utilizados bancos de dados em formato CSV contendo informações temporais de diferentes contextos. Foram utilizadas bibliotecas específicas para manipulação e visualização de dados, como dplyr, ggplot2, lubridate e tidyr.

Inicialmente, os dados foram importados e organizados em formato adequado para séries temporais. Em seguida, foram construídos gráficos para visualização do comportamento das séries ao longo do tempo. Posteriormente, foram realizadas transformações na frequência temporal

dos dados, convertendo as séries para escalas mensais e trimestrais, com o objetivo de comparar os padrões observados e verificar possíveis mudanças na interpretação das séries.

Os conjuntos de dados utilizados foram:

- Dados climáticos extraído do kaggle;
- O dataset dos dados covid;
- O dataset dos dados desmatamento

Resultados e Discussões

Pacotes que serão utilizados na análise

```
library(tidyverse)
```

Warning: pacote 'tidyverse' foi compilado no R versão 4.5.3

Warning: pacote 'ggplot2' foi compilado no R versão 4.5.2

Warning: pacote 'dplyr' foi compilado no R versão 4.5.2

Warning: pacote 'forcats' foi compilado no R versão 4.5.3

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.1.4      v readr      2.1.5
v forcats    1.0.1      v stringr    1.5.2
v ggplot2    4.0.1      v tibble     3.3.0
v lubridate  1.9.4      v tidyr      1.3.1
v purrr      1.1.0
```

```
-- Conflicts ----- tidyverse_conflicts() --
```

```
x dplyr::filter() masks stats::filter()
```

```
x dplyr::lag()     masks stats::lag()
```

```
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(lubridate)
library(forecast)
```

Warning: pacote 'forecast' foi compilado no R versão 4.5.3

```
library(tseries)
```

Warning: pacote 'tseries' foi compilado no R versão 4.5.3

Registered S3 method overwritten by 'quantmod':
 method from
 as.zoo.data.frame zoo

```
library(ggplot2)  
library(gridExtra)
```

Warning: pacote 'gridExtra' foi compilado no R versão 4.5.2

Anexando pacote: 'gridExtra'

O seguinte objeto é mascarado por 'package:dplyr':

```
combine
```

Questão 1) a- Importação dos dados

```
# Leitura do dataset  
dados <- read.csv("C:/Users/dudas/OneDrive/Área de Trabalho/disciplinas_do_7_periodo/series_t  
  
# Visualizar estrutura  
str(dados)
```

```
'data.frame':  1462 obs. of  5 variables:  
 $ date      : chr  "2013-01-01" "2013-01-02" "2013-01-03" "2013-01-04" ...  
 $ meantemp  : num  10 7.4 7.17 8.67 6 ...  
 $ humidity  : num  84.5 92 87 71.3 86.8 ...  
 $ wind_speed : num  0 2.98 4.63 1.23 3.7 ...  
 $ meanpressure: num  1016 1018 1019 1017 1016 ...
```

```
# Converter coluna de data
dados$date <- ymd(dados$date)

# Ordenar por data
dados <- dados %>%
  arrange(date)

# Verificar dados
head(dados)
```


	date	meantemp	humidity	wind_speed	meanpressure
1	2013-01-01	10.000000	84.50000	0.000000	1015.667
2	2013-01-02	7.400000	92.00000	2.980000	1017.800
3	2013-01-03	7.166667	87.00000	4.633333	1018.667
4	2013-01-04	8.666667	71.33333	1.233333	1017.167
5	2013-01-05	6.000000	86.83333	3.700000	1016.500
6	2013-01-06	7.000000	82.80000	1.480000	1018.000

Aqui fizemos a leitura dos dados originais do conjunto de dados. Ele é totalmente dedicado a desenvolvedores que desejam treinar modelos de previsão do tempo para o clima indiano. Contendo informações de janeiro de 2013 á Abril de 2017 na cidade de Delhi, Índia. E os 4 parâmetros dessa base de dados são: temperatura, média,umidade, velocidade do vento e pressão média.

Questão b e c- Gráficos das séries temporais e Interpretação das series

Temperatura

```
ggplot(dados,
       aes(x = date,
           y = meantemp)) +
  geom_line(color = "steelblue") +
  labs(title = "Série Temporal - Temperatura Média",
       x = "Tempo",
       y = "Temperatura") +
  theme_minimal()
```




Interpretação

A série de temperatura apresentou um comportamento de série sazonal evidente, com padrões periódicos de aumento e redução ao longo do tempo. Não foi observada tendência significativa de crescimento ou queda, indicando estabilidade na média da série.

Umidade

```
ggplot(dados,  
  aes(x = date,  
      y = humidity)) +  
  geom_line(color = "darkred") +  
  labs(title = "Série Temporal - Umidade",  
       x = "Tempo",  
       y = "Umidade") +  
  theme_minimal()
```




Interpretação

Para o gráfico da variável umidade, observa-se que ela é uma série sazonal. Pois ao passar dos anos ela fica oscilando sem evidencia clara de crescimento ou queda continua ao longo do tempo.

Velocidade do vento

```
ggplot(dados,  
  aes(x = date,  
      y = wind_speed)) +  
  geom_line(color = "darkgreen") +  
  labs(title = "Série Temporal - Velocidade do Vento",  
       x = "Tempo",  
       y = "Velocidade do vento") +  
  theme_minimal()
```

Série Temporal – Velocidade do Vento




Interpretação

Para o gráfico da variável velocidade do vento observa-se que existe uma forte variabilidade, com possíveis padrões sazonais e sem presença de tendência clara. Portanto, o gráfico acima apresenta uma série sazonal fraca, comparado as de temperatura e umidade. Entretanto, existe alguns periodos que o vento aumenta e outros que diminui. E esse comportamento é repetido várias vezes ao longo dos anos.

Pressão atmosférica

```
ggplot(dados,
       aes(x = date,
           y = meanpressure)) +
  geom_line(color = "purple") +
  labs(title = "Série Temporal - Pressão Atmosférica",
       x = "Tempo",
       y = "Pressão") +
  theme_minimal()
```

Interpretação

A série temporal da pressão atmosférica apresenta um comportamento relativamente estável ao longo do período analisado, sem evidências claras de tendência ou sazonalidade significativa. Entretanto, observa-se diversos valores extremos (outliers), incluindo picos muito elevados indicando possíveis inconsistências nos dados ou falhas de medição. Esses valores anômalos afetam a visualização e interpretação da série, sendo recomendável o tratamento dos dados antes de uma análise.

Questão d - Mudando a medida de tempo das séries para mensal e repetindo as análises da letra a e c temos:

Transformação os dados para mensal

```
dados$date <- as.Date(dados$date)

dados_mensal <- dados %>%
  group_by(mes = floor_date(date, "month")) %>%
  summarise(
```

```

meantemp = mean(meantemp),
humidity = mean(humidity),
wind_speed = mean(wind_speed),
meanpressure = mean(meanpressure)
)

```


Gráficos mensais

Temperatura

```

ggplot(dados_mensal, aes(mes, meantemp)) +
  geom_line(color = "steelblue") +
  theme_minimal() +
  labs(title = "Temperatura Média - Mensal")

```




Interpretação

Observa-se que depois da transformação dos dados para mensal, ficou mais claro e fácil de ver a presença da sazonalidade. Nota-se padrões periódicos bem definidos de aumento e redução da temperatura ao longo dos anos.

Umidade

```
ggplot(dados_mensal, aes(mes, humidity)) +  
  geom_line(color = "darkred") +  
  theme_minimal() +  
  labs(title = "Umidade - Mensal")
```




Interpretação

Observa-se que depois da transformação dos dados para mensal, teve uma suavização as oscilação de curto prazo, reduzindo o ruído e tornando o comportamento sazonal mais perceptível.

Vento (mensal)

```
ggplot(dados_mensal, aes(mes, wind_speed)) +  
  geom_line(color = "darkgreen") +  
  theme_minimal() +  
  labs(title = "Velocidade do Vento - Mensal")
```




Interpretação

Observa-se que depois da transformação dos dados para mensal, o comportamento sazonal da série ficou mais evidente e fácil percepção. Onde vemos que a velocidade do vento fica oscilando ao decorrer dos anos.

Pressão (mensal)

```
ggplot(dados_mensal, aes(mes, meanpressure)) +  
  geom_line(color = "purple") +  
  theme_minimal() +  
  labs(title = "Pressão Atmosférica - Mensal")
```



Interpretação

Observa-se que depois da transformação dos dados para mensal, temos uma melhor visualização. Nota-se que existe alguns picos elevados e baixos da pressão atmosférica.

Questão e mudando a medida de tempo das séries para trimestral e repetindo as análises da letra a e c temos:

Transformação para trimestral


```
dados$date <- as.Date(dados$date)

dados_trimestral <- dados %>%
  group_by(trimestre = floor_date(date, "quarter")) %>%
  summarise(
    meantemp = mean(meantemp),
    humidity = mean(humidity),
    wind_speed = mean(wind_speed),
    meanpressure = mean(meanpressure)
  )
```

Gráficos trimestrais


Temperatura

```
ggplot(dados_trimestral, aes(trimestre, meantemp)) +  
  geom_line(color = "steelblue") +  
  theme_minimal() +  
  labs(title = "Temperatura Média - Trimestral")
```




Umidade

```
ggplot(dados_trimestral, aes(trimestre, humidity)) +  
  geom_line(color = "darkred") +  
  theme_minimal() +  
  labs(title = "Umidade - Trimestral")
```




Vento

```
ggplot(dados_trimestral, aes(trimestre, wind_speed)) +  
  geom_line(color = "darkgreen") +  
  theme_minimal() +  
  labs(title = "Velocidade do Vento - Trimestral")
```



Pressão

```
ggplot(dados_trimestral, aes(trimestre, meanpressure)) +  
  geom_line(color = "purple") +  
  theme_minimal() +  
  labs(title = "Pressão Atmosférica - Trimestral")
```

Conclusão

Portanto, concluímos que a análise das séries temporais climáticas de Delhi mostrou que as variáveis temperatura e umidade apresentam sazonalidade mais evidente, com padrões que se repetem ao longo do tempo. A velocidade do vento apresentou maior variabilidade e sazonalidade mais fraca, enquanto a pressão atmosférica mostrou comportamento mais estável, porém com presença de valores extremos. Após a transformação das séries para frequência mensal e trimestral, os ruídos das oscilações diárias foram reduzidos, tornando os padrões sazonais mais visíveis e facilitando a interpretação das séries temporais.

Questão 2) a e b- Escolher um país e construir os gráficos das séries para cada variável e identificando características que estão presentes nas séries

O banco de dados todo é dado por:

Irei escolher o Brasil para fazer a minha análise e concluir sobre ela.

Baixando o banco de dados completo e filtrando o Brasil para as análises

```
# Carregando a base de dados
dados <- read.csv("C:/Users/dudas/OneDrive/Área de Trabalho/disciplinas_do_7_periodo/series


# Transformando a data
dados$date <- as.Date(dados$date)

# Filtrando apenas o Brasil
brasil <- dados %>%
  filter(location == "Brazil")
```

Gráficos das séries

Total de vacinações

```
ggplot(brasil, aes(x = date, y = total_vaccinations)) +
  geom_line(color = "blue") +
  labs(title = "Total de vacinações - Brasil",
        x = "Data",
        y = "Total de doses") +
  theme_minimal()
```



Interpretação


As características observadas da série do total de vacinação são:

- Forte tendência crescente;
- Tem um crescimento contínuo ao longo do tempo;
- Ausência de sazonalidade;
- É uma série não estacionária.

Portanto, conclui-se que a série apresenta um comportamento acumulativo, aumentando continuamente conforme novas doses são aplicadas na população.

Pessoas vacinadas

```
ggplot(brasil, aes(x = date, y = people_vaccinated)) +  
  geom_line(color = "darkgreen") +  
  labs(title = "Pessoas vacinadas - Brasil",  
        x = "Data",  
        y = "Pessoas vacinadas") +  
  theme_minimal()
```



Interpretação

As características observadas da série de pessoas vacinadas é:

- Tendência crescente;
- Tem um crescimento acelerado no início e desaceleração posteriormente;
- Ausência de sazonalidade;
- Tem um comportamento semelhante a de uma curva logística.


Portanto, conclui-se que o número de pessoas vacinadas cresce rapidamente no início da campanha da vacinação e depois desacelera à medida que grande parte da população já tenha sido vacinada.

Pessoas totalmente vacinadas

```
ggplot(brasil, aes(x = date, y = people_fully_vaccinated)) +  
  geom_line(color = "purple") +  
  labs(title = "Pessoas totalmente vacinadas - Brasil",  
        x = "Data",
```

```
y = "Pessoas totalmente vacinadas") +  
theme_minimal()
```

Warning: Removed 19 rows containing missing values or values outside the scale range (``geom_line()``).



Interpretação

As características observada da série de pessoas totalmente vacinadas é:


- Tendência crescente;
- Crescimento com atraso em relação à primeira dose;
- Ausência de sazonalidade;
- É uma série não estacionária.

Portanto, conclui-se que a série acompanha a imunização completa da população. E o atraso em relação à série de pessoas vacinadas ocorre devido ao intervalo necessário entre cada doses.

Vacinação diária

```
ggplot(brasil, aes(x = date, y = daily_vaccinations)) +  
  geom_line(color = "red") +  
  labs(title = "Vacinação diária - Brasil",  
        x = "Data",  
        y = "Doses diárias") +  
  theme_minimal()
```

Warning: Removed 1 row containing missing values or values outside the scale range (`geom\_line()`).



Interpretação

As características observada da série da vacinação diária é:

- Oscilação ao longo do tempo;
- Presença de picos e quedas;
- Ausência de sazonalidade definida;
- Uma alta variabilidade.

Portanto, conclui-se que a vacinação diária sofre influência da disponibilidade de vacinas, campanhas de imunização, logística de distribuição e políticas públicas. Os picos representam períodos de maior aplicação de doses.

Conclusão

Concluimos que as séries acumulativas de vacinação apresentam uma forte tendência crescente ao longo do tempo, característica típica de variáveis acumuladas. Essas séries não apresentaram sazonalidade, pois não possuem padrões periódicos que se repetem regularmente. Já a série de vacinação diária apresentou oscilações, com períodos de crescimento e redução no número de doses aplicadas, refletindo mudanças no ritmo da campanha de vacinação. Apesar das flutuações observadas, não foi identificada sazonalidade clara na série.

Questão 3) a e b - Construindo gráficos das séries para cada estado e identificando características que estão presentes nas séries

Importação e preparação dos dados

```
# Leitura da base
dados <- read.csv("C:/Users/dudas/OneDrive/Área de Trabalho/disciplinas_do_7_periodo/series_

# Visualizar estrutura
str(dados)
```

```
'data.frame':  35 obs. of  11 variables:
 $ referencia      : int  1988 1989 1990 1991 1992 1993 1994 1995 1996 1997 ...
 $ acre            : int  620 540 550 380 400 482 482 1208 433 358 ...
 $ amazonas        : int  1510 1180 520 980 799 370 370 2114 1023 589 ...
 $ amapa           : int  60 130 250 410 36 0 0 9 0 18 ...
 $ maranhao        : int  2450 1420 1100 670 1135 372 372 1745 1061 409 ...
 $ mato_grosso     : int  5140 5960 4020 2840 4674 6220 6220 10391 6543 5271 ...
 $ para            : int  6990 5750 4890 3780 3787 4284 4284 7845 6135 4139 ...
 $ rondonia        : int  2340 1430 1670 1110 2265 2595 2595 4730 2432 1986 ...
 $ roraima         : int  290 630 150 420 281 240 240 220 214 184 ...
 $ tocantins       : int  1650 730 580 440 409 333 333 797 320 273 ...
 $ area_total_desmatamento: int  21050 17770 13730 11030 13786 14896 14896 29059 18161 13227
```

Gráficos das séries temporais


Aqui estão todas as séries por estado

```
library(dplyr)
library(tidyr)
library(ggplot2)

dados_long <- dados %>%
  pivot_longer(
    cols = acre:tocantins,
    names_to = "estado",
    values_to = "desmatamento"
  )

ggplot(dados_long,
  aes(x = referencia,
      y = desmatamento,
      color = estado)) +
  geom_line() +
  facet_wrap(~estado, scales = "free_y") +
  theme_minimal() +
  labs(title = "Séries temporais do desmatamento por estado",
    x = "Ano",
    y = "Área desmatada")
```


Séries temporais do desmatamento por estado



Interpretação das séries

As séries temporais de desmatamento apresentaram comportamentos distintos entre os estados analisados. Os estados do Pará e Mato Grosso apresentaram os maiores níveis de desmatamento ao longo dos anos, com períodos de forte crescimento seguidos de redução.

O estado do Amazonas apresentou tendência de crescimento mais recente, indicando aumento do desmatamento nos últimos anos. Já Rondônia apresentou grandes oscilações ao longo do período, enquanto Tocantins mostrou tendência de redução contínua do desmatamento.

Os estados do Acre, Amapá, Maranhão e Roraima apresentaram menor intensidade de desmatamento, porém com variações ao longo do tempo.

De modo geral, observa-se presença de tendência em algumas séries, principalmente associada ao aumento ou redução do desmatamento em determinados períodos. Entretanto, não foi identificada sazonalidade clara, pois os dados anuais não apresentam padrões periódicos que se repetem regularmente ao longo do tempo.